

Literatur-Seminar-Arbeit

Vorhersagen von Verkehrsunfällen mithilfe künstlicher neuronaler Netze

Erik Rohr

Fachbereich Informatik (02) - Hochschule Bonn-Rhein-Sieg

26. Juni 2024

Betreuerin: Doerthe Vieten

Abstrakt

« Kurz beschreiben »

Inhaltsverzeichnis

1	Einleitung	4
1.1	Theorie	4
1.1.1	Künstliche neuronale Netze (KNN)	4
1.2	Aktuelle Forschungslage	5
1.2.1	Banerjee et al.	5
1.2.2	Maurya et al.	5
1.2.3	Zohra et al.	6
2	Methodik	6
2.1	Die PRISMA-Leitlinie	6
2.2	Prozess der Recherche	6
2.3	In- und Exklusionskriterien	7
3	Ergebnisse	7
3.1	Limitationen	7
4	Diskussion und Fazit	7
4.1	Diskussion	7
4.2	Fazit	8
4.3	Ausblick auf zukünftige Forschung	8

1 Einleitung

Jedes Jahr sterben weltweit ca. 1,19 Millionen Menschen in Verkehrsunfällen (RTA, engl.: „road traffic accident“) [1]. Eine umfassende Analyse vorliegender Verkehrsdaten im Hinblick auf potentielle Bedrohungen kann dazu beitragen, Baumaßnahmen unfallminimierend zu gestalten.

Vorangehende Analysen von Verkehrsdaten, die eine Vielzahl an „Machine Learning“-Modelle nutzten, haben ergeben, dass eine Vielzahl an Faktoren existieren, die das Risiko auf RTA erhöhen, wie Wetterbedingungen, Straßenkonditionen, Zustand des Fahrers, Lichtverhältnisse, Tageszeit und die Verkehrsdichte [2, 3]. „Machine Learning“-Modelle (ML) sind darauf ausgelegt, nicht anhand von spezifischen Anweisungen, sondern allein durch das Erkennen von Mustern und Abhängigkeiten mithilfe komplexer Funktionen [3] in Daten Erkenntnisse zu ziehen und Entscheidungen sowie Vorhersagen treffen zu können [4].

Unter den ML-Modellen werden künstliche neuronale Netze (KNN) für diesen Anwendungsfall bevorzugt, da diese keine zugrundeliegenden Beziehungen zwischen den Eingangsvariablen benötigen und darauf ausgelegt sind, mit historischen Daten Aussagen über die Zukunft treffen zu können [3].

In dieser Arbeit wird eine systematische Literaturrecherche (SLR) zur Vorhersage von RTAs mithilfe KNNs dargestellt. Die Ergebnisse werden im Hinblick auf deren Mehrwert in der Minimierung von Straßenverkehrsunfällen durch unsichere Straßenarchitektur untersucht und eingeordnet.

1.1 Theorie

1.1.1 Künstliche neuronale Netze (KNN)

Künstliche neuronale Netze (KNN) sind ein Teilbereich der ML-Modelle. Sie können Entscheidungen auf ähnlicher Art und Weise treffen, wie das menschliche Gehirn [5]. Das Modell besteht aus einer Vielzahl von Schichten mit unterschiedlich vielen Knoten. Diese Knoten sind mit anderen Knoten aus den benachbarten Schichten verbunden und besitzen sogenannte „weights“ und „bias“ [5]. Eingabedaten werden von der „input layer“ (Deutsch: „Eingangsschicht“) entlang aller hidden layer (Deutsch: „verborgene Schicht“) durchgereicht, verarbeitet und schließlich in der „output layer“ (Deutsch: „Ausgangsschicht“) aggregiert ausgegeben [5].

Zur Konfigurierung von KNN können unter anderem die Anzahl der Schichten, die Optimierungsverfahren (engl.: „optimizers“), die Aktivierungsfunktion (engl.: „activation

function“) und die Verlustsfunktion (engl.: „loss function“) frei gewählt werden [6].

Ein Optimierungsverfahren ist eine Funktion oder ein Algorithmus, welches Parameter der Knoten wie die Gewichte und die Lernrate (engl.: „learning rate“) anpasst, um den Verlust zu minimieren, die Genauigkeit zu maximieren und die benötigte Trainingszeit exponentiell zu reduzieren [6]. Beispiele für solche Optimierungsverfahren sind der „gradient descent“, „RMS prop (Root Mean Square)“ und „adam’s optimizer“ [6].

Die Aktivierungsfunktion entscheidet, wie der kalkulierte Ausgangswert eines Knotens zu interpretieren ist. Dies fügt dem Netz eine Nicht-Linearität hinzu [6]. Somit können die verborgenen Schichten jeweils für andere Bereiche der Interpretation der Daten stehen. Linearität würde auf der anderen Seite bedeuten, dass das Netz in eine Funktion zusammengefasst werden könnte [6]. Beispiele sind die binäre „step function“, die Sigmoid-Funktion und die „RELU“-Funktion [6].

Eine Verlustsfunktion misst, wie genau das KNN den Datensatz modelliert, indem es den vorliegenden Verlust (engl.: „loss“) berechnet [6]. Gängige Funktionen sind die „Mean Squared Error“-Funktion und die „Binary Cross Entropy“-Funktion [6].

1.2 Aktuelle Forschungslage

1.2.1 Banerjee et al.

Eine Vielzahl an Klassifizierern (engl.: „classifiers“) sind mit KNN-Modellen bezüglich Vorhersage der Mortalität in RTAs verglichen worden. Darunter gehören Random Forest, Support Vector Machine, K-Nearest Neighbor Classifier, AdaBoost Classifier, XGBoost Classifier. Hierbei hat das KNN mit 7 „hidden layer“, 1 „input layer“, Adams Optimizer und einer „dropout class“ in der Eingangsschicht die beste Genauigkeit von 84,36% erzielt [7].

1.2.2 Maurya et al.

Vorhersehen von Kraftfahrzeuggeschwindigkeiten dienen als Basis für ein fortgeschrittenes Verkehrsmanagementsystem [8]. Hierbei wurden Lineare Regression, „random forest“-Regression, „Decision Tree“ und ein KNN miteinander Vergleichen und eine „Performance Analyse“ durchgeführt. KNN und die „random forest“-Regression haben mit einem „R squared“-Wert ¹ von jeweils 0,9301 und 0,9642 das beste Fitting erzielt [8].

¹Bestimmtheitsmaß. Stellt die Anpassungsgüte einer Regression dar [9]

1.2.3 Zohra et al.

Anhand den Datensätzen aus „US Accidents (2016-2023)“ wurden ein KNN, ein Random Forest Klassifizierer und eine logistische Regression trainiert und getestet. Hier wurden jeweils Genauigkeitswerte von 81,1%, 90,7% und 87,03% erreicht [10].

2 Methodik

Im Folgenden wird die Vorgehensweise bei der Literaturrecherche beschrieben. Die Vorgehensweise orientiert sich an der PRISMA-Leitlinie (Preferred Reporting Items for Systematic Reviews and Meta-Analyses). PRISMA hat sich ursprünglich als effektiver Vorreiter bzgl. SLR im medizinischen Sektor etabliert, mit dem Fachkräfte auf dem aktuellen Stand der Wissenschaft bleiben und bestehende Vorschriften aktualisiert werden [11]. Entnehmend der zahlreichen SLR-Veröffentlichungen in Bereichen der Informatik (siehe Datenbanken ACM/IEEE), hat sich PRISMA als hilfreiches Mittel zur SLR auch in anderen Wissenschaftsbereichen bewiesen.

2.1 Die PRISMA-Leitlinie

PRISMA beinhaltet eine aus 27 Stichpunkten bestehende „Checkliste“ und ein 4-phasiges Fluss-Diagramm [11]. Da diese allerdings ursprünglich für die Medizin entwickelt wurden, werden jene auf die angepasst Informatik für die Basis der SLR verwendet. Mithilfe dieser Elemente kann sowohl Literatur systematisch für die Aufnahme in einer SLR auf Eignung geprüft als auch der Prozess erleichtert und standardisiert werden.

Zunächst werden Forschungsfragen aufgestellt, die im Laufe der Recherche beantwortet werden sollen. Im Anschluss wird dann die Literatur anhand der ausgewählten Such-Strategie ausgewählt. Die gesammelte Literatur wird dann durch Ein- und Ausschlusskriterien gefiltert und auf Eignung für die SLR durch die Checkliste geprüft. Schließlich werden aus der eingeschlossenen Literatur qualitative und quantitative Daten extrahiert, mit anderer Literatur verglichen und in der eigentlichen Literaturanalyse zusammengetragen.

2.2 Prozess der Recherche

Für die Literaturrecherche sind die Datenbanken ACM Digital Library und die IEEE Explore verwendet worden, da diese überwiegend Artikel in der Informatik veröffentlicht haben. Hierbei wurden die folgenden Suchstrings verwendet:

ACM Digital Library

```
[All: "neural network?"] AND [ [All: "traffic flow"] OR [All: "traffic control"] OR  
[All: "accident"] ] AND [E-Publication Date: (01/01/2023 TO 12/31/2024)]
```

IEEE Explore

```
("All Metadata": "artificial neural network?") AND ("All Metadata:"traffic")  
AND ("All Metadata:"control" OR "All Metadata:"accident")
```

Zusätzlich ist die Suche auf den Inhaltstyp „Research Article“ und die Verfügbarkeit „Open Access“ begrenzt worden, soweit von den Einstellungen der Datenbank möglich.

2.3 In- und Exklusionskriterien

Die für diese Arbeit relevanten Artikel sind auf solche beschränkt worden, die

1. eine Verkehrsdatenanalyse betreiben und diese mit einer KNN auswerten,
2. ggf. einen quantitativen Vergleich verschiedener ML-Modelle durchführen oder
3. quantitative Merkmale der KNN aufzählen.

Zu letzterem Punkt gehören Merkmale wie gewählte Netztopologie, Anzahl der Schichten, Anzahl der Knoten pro Schicht, gewähltes Optimierungsverfahren, die gewählte Aktivierungsfunktion Genauigkeit und Eingangsvariablen.

3 Ergebnisse

« Erkenntnisse aus den Studien zusammentragen, auswerten und diskutieren »

3.1 Limitationen

« Grenzen dieser Arbeit auflisten »

4 Diskussion und Fazit

4.1 Diskussion

« Forschungsfrage aufgreifen und beantworten »

4.2 Fazit

«< Zusammenfassen >>

4.3 Ausblick auf zukünftige Forschung

«< Selbsterklärend >>

Literatur

- [1] World Health Organization (WHO). *Road Traffic Injuries*. 2023. URL: <https://www.who.int/news-room/fact-sheets/detail/road-traffic-injuries>.
- [2] Surojit Das et al. „Machine Learning Based Approach for Predicting the Impact of Time of Day on Traffic Accidents“. In: (2023). DOI: 10.1109/ICCIT60459.2023.10441325.
- [3] Ruyi Qian und Xin Wang. „Prediction of accident severity based on BP neural networks“. In: (2023). DOI: 10.1109/CCDC58219.2023.10327407.
- [4] Systemanalyse Programmentwicklung (SAP). *Was ist Machine Learning?* 2024. URL: <https://www.sap.com/germany/products/artificial-intelligence/what-is-machine-learning.html>.
- [5] International Business Machines Corporation (IBM). *Was ist ein neuronales Netz?* 2024. URL: <https://www.ibm.com/de-de/topics/neural-networks>.
- [6] Deeksha Goplani. *Activation functions, loss functions & Optimizers*. 2023. URL: <https://medium.com/@deeksha.goplani/activation-functions-loss-functions-optimizers-6bd0316898ae>.
- [7] Amitayas Banerjee et al. „Comparative Analysis of Machine Learning and ANN models for Mortality prediction in RTAs“. In: *2023 OITS International Conference on Information Technology (OCIT)*. 2023, S. 698–702. DOI: 10.1109/OCIT59427.2023.10431379.
- [8] Ayush Maurya et al. „A Key Factor in Traffic Management - Vehicle Speed Prediction Using Machine Learning“. In: *2023 4th International Conference on Computation, Automation and Knowledge Management (ICCAKM)*. 2023, S. 1–6. DOI: 10.1109/ICCAKM58659.2023.10449542.
- [9] Jim Frost. *How to interpret R-squared in Regression Analysis*. o. A. URL: <https://statisticsbyjim.com/regression/interpret-r-squared-regression/>.

- [10] Ennaji Fatima Zohra et al. „Accident Severity Prediction using Machine Learning: A case study on the US Accidents Dataset“. In: *2023 17th International Conference on Signal-Image Technology & Internet-Based Systems (SITIS)*. 2023, S. 242–246. DOI: 10.1109/SITIS61268.2023.00044.
- [11] David Moher et al. „Preferred Reporting Items for Systematic Reviews and Meta-Analyses: The PRISMA Statement“. In: (2009). DOI: 10.1371/journal.pmed.1000097.

Abbildungsverzeichnis

Tabellenverzeichnis